Prédiction du Niveau de Risque de Cancer

Projet Machine Learning End-to-End

Classification | scikit-learn | Streamlit

885	23	5	98.3%
Patients	Features	Modèles	Accuracy

Dorra Mani & Rania dabbek

Contexte & Dataset

Problématique

Prédire le niveau de risque de cancer d'un patient à partir de ses symptômes.

Type : Classification multi-classe

Low — Risque faible
Medium — Risque modéré
High — Risque élevé

Dataset

Source	Kaggle
Lignes	1100 (885 valides)
Features	23 variables médicales
Target	Low / Medium / High
Doublons	33 supprimés
NaN target	215 → dropna()

Analyse Exploratoire des Données (EDA)

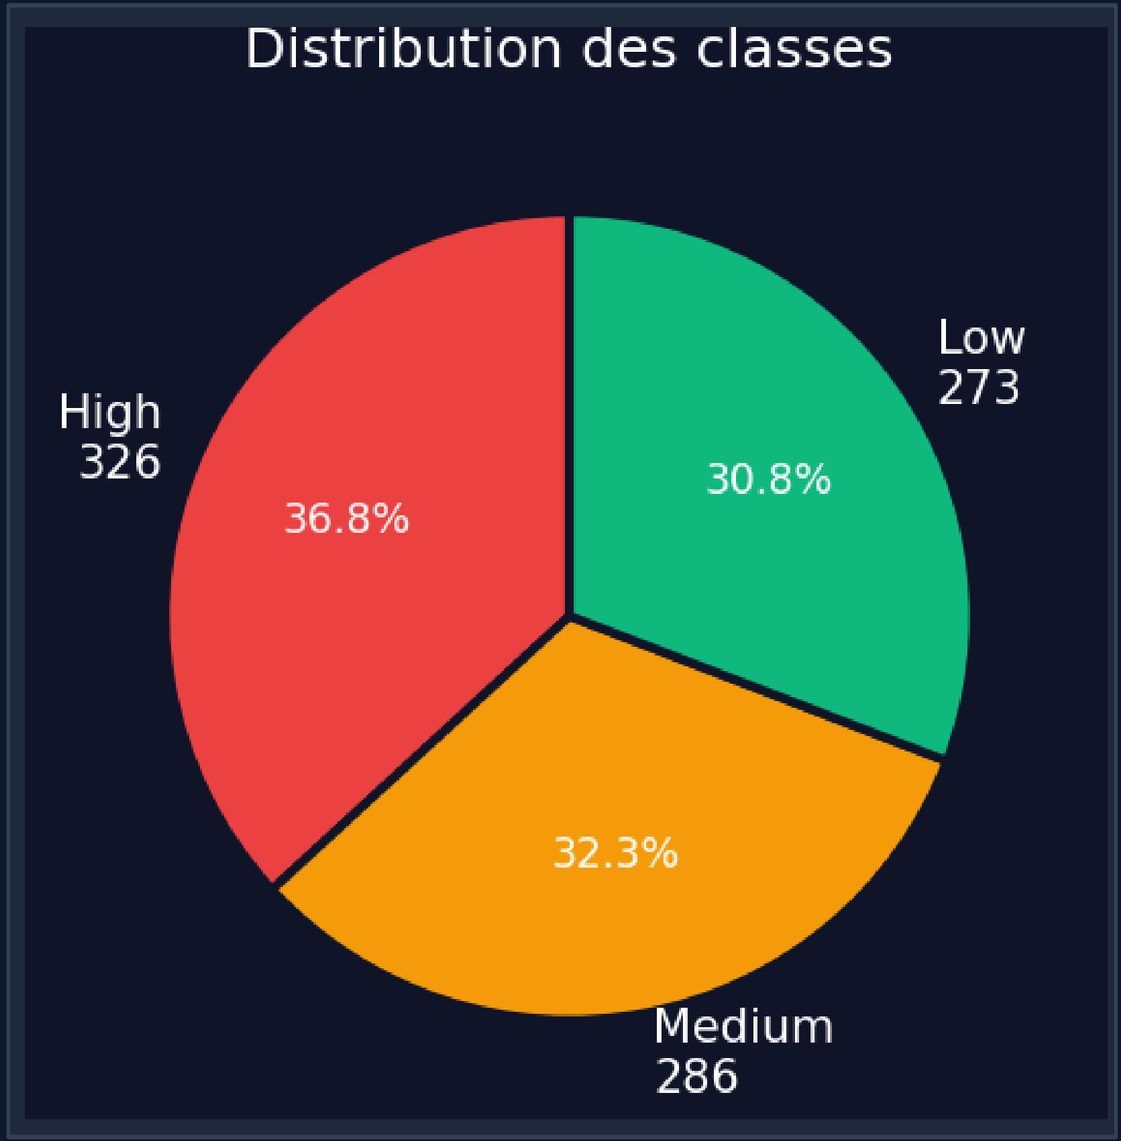

Observations Clés

- Dataset équilibré — pas besoin de SMOTE
- 215 NaN dans la TARGET (Level)
- Corrélations fortes : Smoking ↔ Lung Disease
- Outliers détectés sur 4 colonnes (clipping)
- Toutes les features sont numériques (1-9)

Préprocessing & Fix Critique

Fix Critique Découvert

215 lignes avaient NaN dans la TARGET → fillna(median) créait un 4ème label fictif → Accuracy faussement basse : 64%-79%

Sans fix : 64% - 79%

Avec fix : 98.3%

Pipeline de Préprocessing

Étape 1	Étape 2	Étape 3	Étape 4	Étape 5
dropna(['Level'])	fillna(median)	LabelEncoder	clip(upper=8)	Train/Test Split
1100 → 885 patients	Imputation features	High/Medium/Low→0/1/2	Correction outliers	80% train / 20% test

Modélisation — Comparaison des 5 Algorithmes

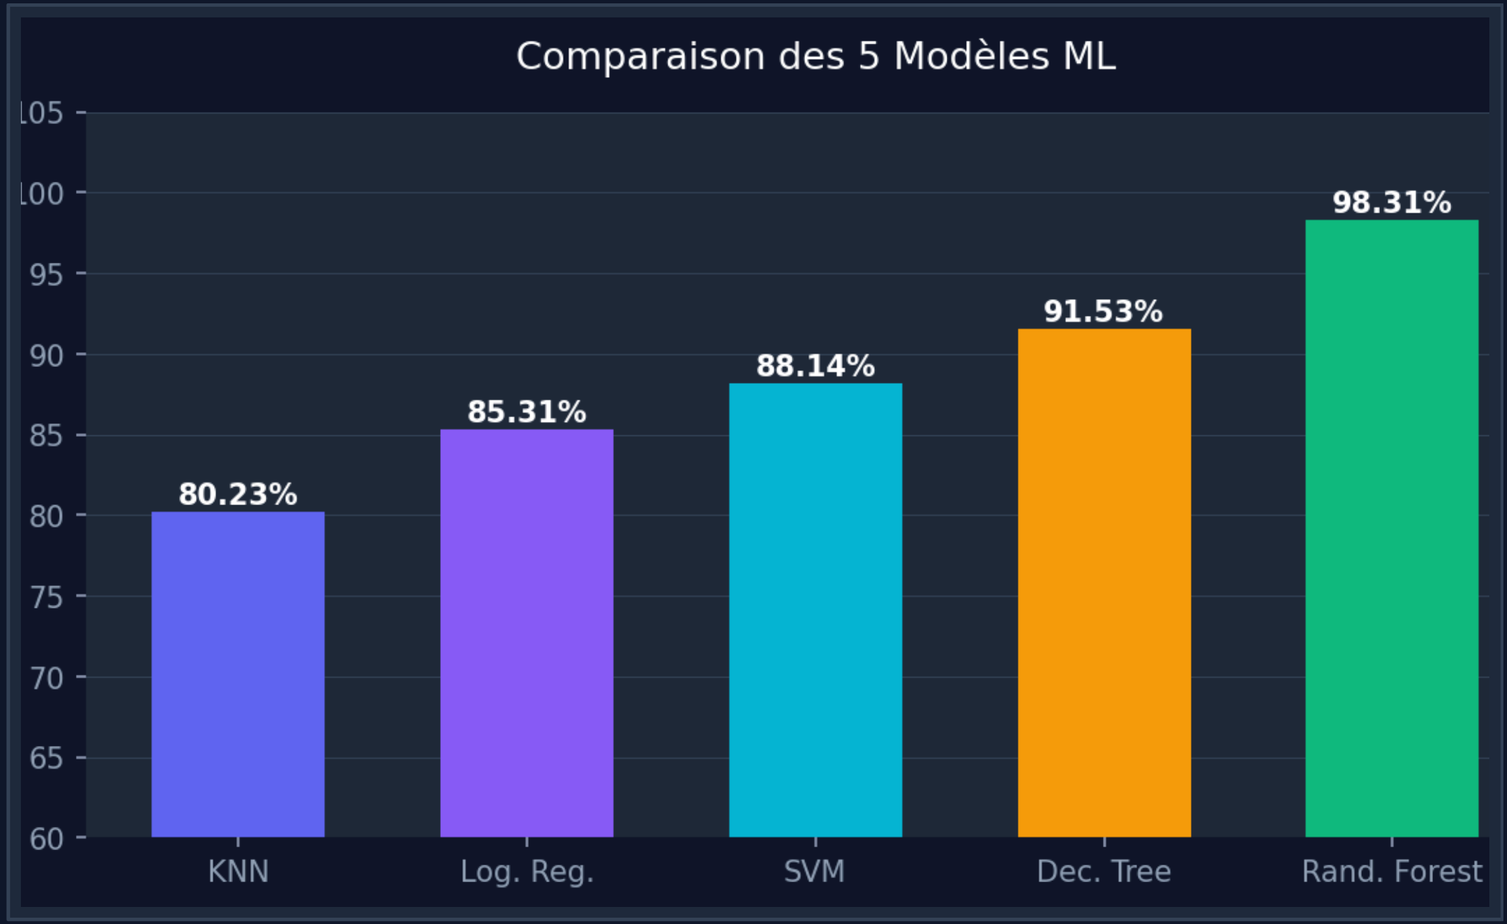

Résultats

KNN	80.23%
Log. Regression	85.31%
SVM (RBF)	88.14%
Decision Tree	91.53%
Random Forest	**98.31%**

StandardScaler appliqué pour SVM, KNN et Logistic Regression — améliore la convergence et la précision

Meilleur Modèle — Random Forest Tuné

98.31%	99.43%	±0.23%	200
Accuracy Test	5-Fold CV	Std CV	n_estimators

GridSearchCV

n_estimators:

[100, 200, 300]

max_depth:

[None, 10, 20]

min_samples_leaf:

[1, 2, 4]

Meilleurs paramètres

n_estimators=200
max_depth=None
min_samples_leaf=1

Application Streamlit — Déploiement

Cancer Risk Predictor

Niveau : LOW — Confiance : 97.3%

Stack Technique

- streamlit — Interface web interactive
- scikit-learn — Modèle Random Forest
- pickle — Sérialisation du modèle
- GitHub + Streamlit Cloud — Déploiement

Déploiement

1. Entraîner & sauvegarder model.pkl
2. Créer app.py (Streamlit)
3. Pousser sur GitHub
4. Déployer sur share.streamlit.io
5. Lien public disponible

Conclusion & Bilan du Projet

98.31%

Accuracy finale

Random Forest Tuné

+34 pts

Gain Fix Critique

dropna(subset=['Level'])

99.43%

Score 5-Fold CV

Robustesse confirmée

Ce qui a été réalisé

- EDA complète avec visualisations
- Fix critique identifié & corrigé
- 5 algorithmes testés & comparés
- Optimisation GridSearchCV
- Application Streamlit déployée
- Repository GitHub organisé

Apprentissages Clés

Qualité des données > algorithme

Toujours vérifier la TARGET en 1er

GridSearch améliore mais modère

Déploiement = valeur ajoutée réelle

Structure GitHub = professionnalisme

Merci pour votre attention — Questions ?